پروژه درس داده کاوی

موضوع: مجموعه داده های بیماران کبدی هند

استاد:

دكتر الهام عباسي

دانشجویان: مجتبی آل حسینی (۹۶۲۷۷۲۳) پردیس عشقی نژاد (۹۵۳۸۸۵۳)



این مجموعه داده شامل ۴۱۶ سوابق بیمار کبدی و ۱۶۷ سوابق افراد بدون بیماری است. مجموعه داده ها از شمال شرق آندرا پرادش هند جمع آوری شده است. این دیتاست شامل دو کلاس است که برای تقسیم به گروه (بیمار کبدی یا نه) استفاده می شود. این مجموعه داده شامل ۴۴۱ سوابق بیمار مرد و ۱۴۲ سوابق بیمار زن است.

هر بیمار که سن او بیش از ۸۹ است، به سن ۹۰ سالگی ذکر شده است.

ویژگی هایی که دراین مجموعه داده مورد توجه قرار گرفته اند عبارت اند از:

\. Age: Age of the patient

Y. Gender: Gender of the patient

۳. TB: Total Bilirubin

*. DB: Direct Bilirubin

۵. Alkphos: Alkaline Phosphotase

۶. Sgpt Alamine Aminotransferase

V. Sgot Aspartate Aminotransferase

A. TP: Total Protiens

9. ALB: Albumin

1. A/G: Ratio Albumin and Globulin Ratio

11. Selector field used to split the data into two sets (labeled by the experts)

نوع مساله: Classification

تعداد داده: ۵۸۳

نرمالسازي ها

با استفاده از روش **مین – ماکس** با فرمول:

v'(i)=[v(i)-min[v(i)]]/[max(v(i)-min(v(i))]

داده ها نرمالسازی شده و در فایل اکسل جداگانه با نام ILPD MinMax.csv ذخیره شده است.

با استفاده از روش **دسیمال** با فرمول:

v'(i)=[v(i)-mean[v(i)]]/sd(v(i))

داده ها نرمالسازی شده و درفایل اکسل جداگانه با نام ILPD Decimal.csv ذخیره شده است.

با استفاده از روش انحراف معيار با فرمول:

 $v'(i)=v(i)/k^i$

داده ها نرمالسازی شده و درفایل اکسل جداگانه با نام ILPD SD.csv ذخیره شده است.

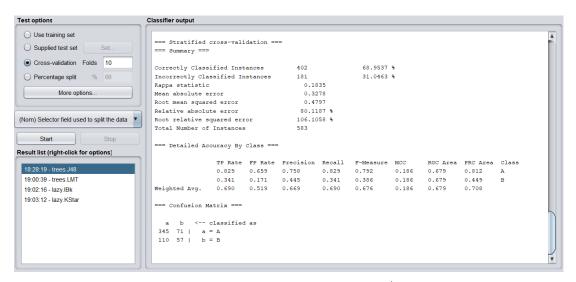
از هر سه داده ی نرمال شده، و داده های خام(که با نام ILPD.csv ذخیره شده است) ، به طور جداگانه با هشت الگوریتم متفاوت دقت گرفته شد و در جداول ثبت شده اند. همچنین با تکنیک انتخاب ویژگی یکبار ویژگی جنسیت حذف شده و با داده های خام و نرمالسازی شده دقت گرفته شده و بار دیگر با انتخاب چند ویژگی و با داده های خام و نرمالسازی شده، دقت گرفته شده و در جداول ثبت شده است.

سناريوها

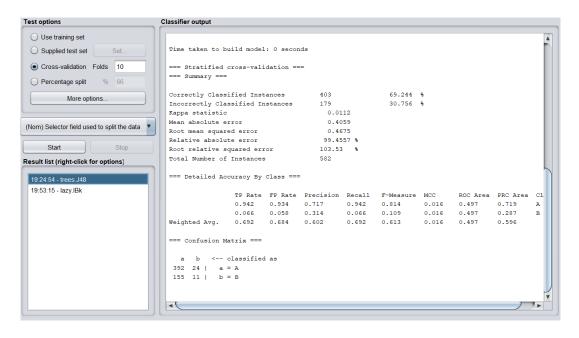
برای هر الگوریتم یک سناریو تعریف و دقت آن بدست آورده شده. همچنین تصویر نرم افزار و کا قرار داده شده است.

$j^{\xi\Lambda}$ پیاده سازی الگوریتم ۱.

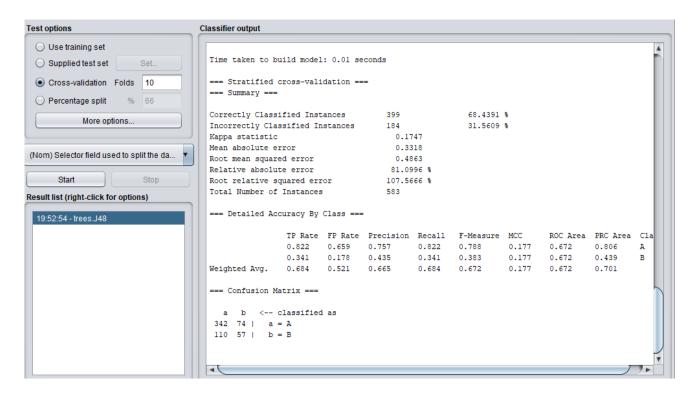
Jέλ				
دقت	نوع داده			
۶۸.۹۵۳۷	داده خام			
99.744	داده نرمال سازی شده با روش مین-ماکس			
8A.4T91	داده نرمال سازی شده با روش دسیمال			
FA.F1 • F	داده نرمال سازی شده با روش انحراف معیار			



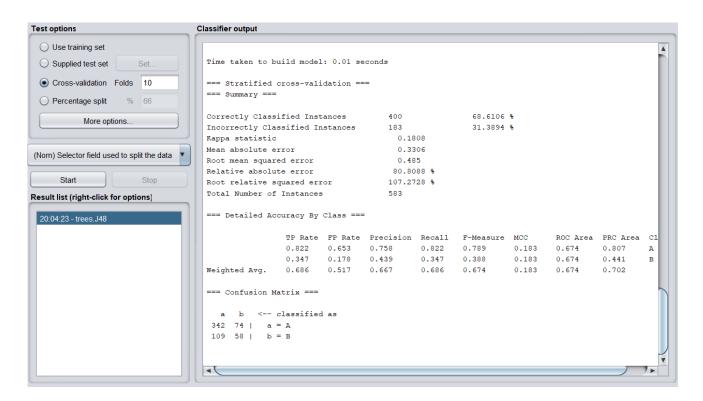
ل يياده سازي الگوريتم j48 در نرم افزار وكا با داده خام



مر پیاده سازی الگوریتم ۴۸j در نرم افزار وکا با داده نرمال سازی شده به روش مین-ماکس

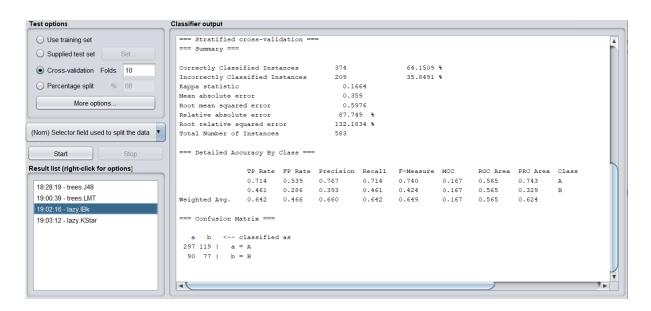


🕊 پیاده سازی الگوریتم ۴۸ در نرم افزار و کا با داده نرمال سازی شده به روش دسیمال

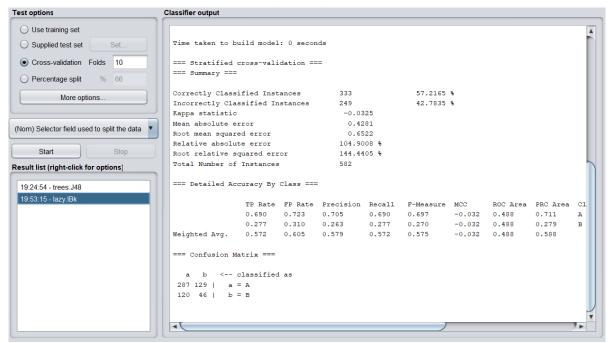


م پیاده سازی الگوریتم ۴۸j در نرم افزار وکا با داده نرمال سازی شده به روش انحراف معیار ۴

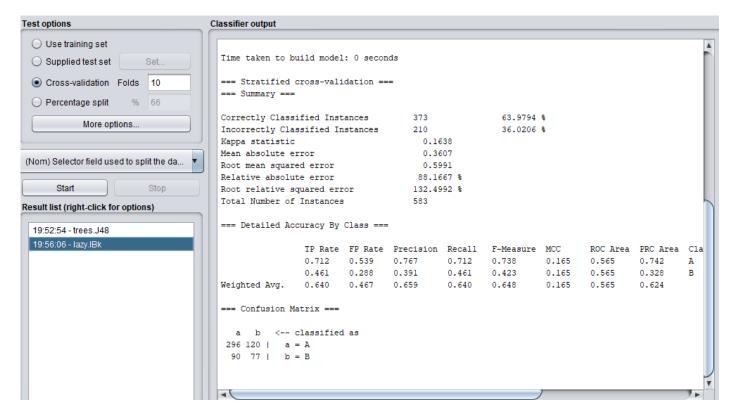
IBK				
دقت	نوع داده			
۶۴.۱۵۰۹	داده خام			
۵۷.۲۱۶۵	داده نرمال سازی شده با روش مین–ماکس			
<i>५</i> ٣.१४१۴	داده نرمال سازی شده با روش دسیمال			
۶۳.۹V9۴	داده نرمال سازی شده با روش انحراف معیار			



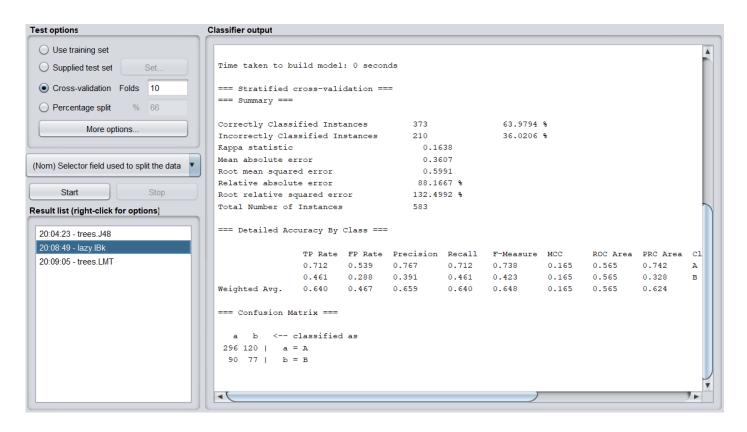
پیاده سازی الگوریتم IBK در نرم افزار و کا با داده خام



م پیاده سازی الگوریتم IBK در نرم افزار و کا با داده نرمال سازی شده به روش مین-ماکس

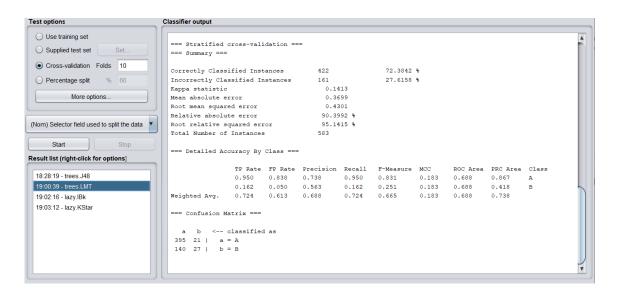


ل پیاده سازی الگوریتم IBK در نرم افزار و کا با داده نرمال سازی شده به روش دسیمال

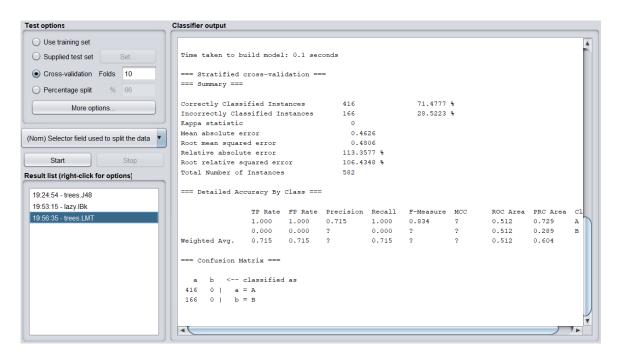


پیاده سازی الگوریتم IBK در نرم افزار وکا با داده نرمال سازی شده به روش انحراف معیار

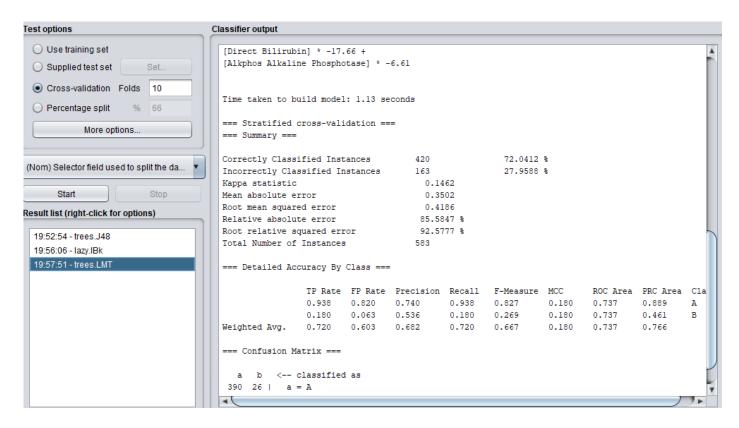
LMT				
دقت	نوع داده			
٧٣.٣٨٣٢	داده خام			
٧١.۴٧٧	داده نرمال سازی شده با روش مین–ماکس			
٧٢.٠۴١٢	داده نرمال سازی شده با روش دسیمال			
٧٢.٠۴١٢	داده نرمال سازی شده با روش انحراف معیار			



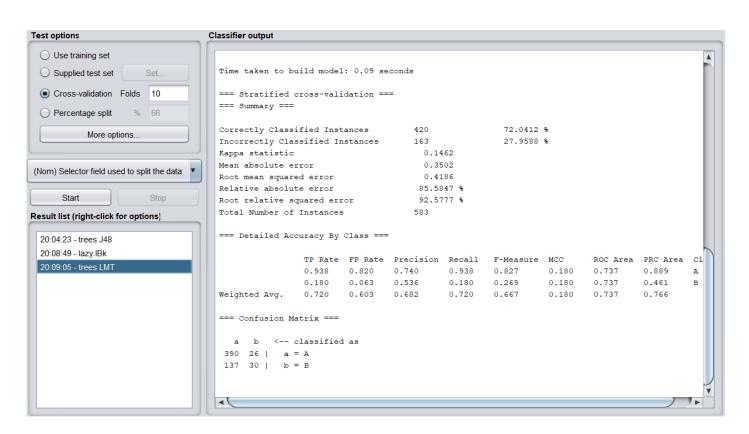
9 پیاده سازی الگوریتم LMT در نرم افزار و کا با داده خام



• ل پیاده سازی الگوریتم LMT در نرم افزار و کا با داده نرمال سازی شده به روش مین-ماکس

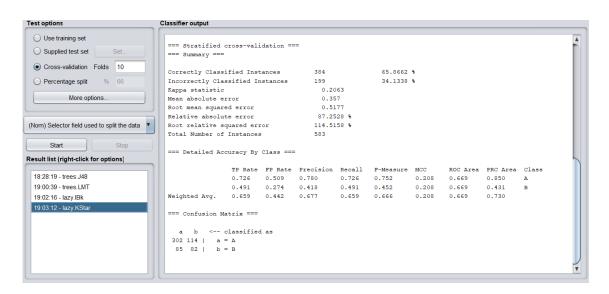


ا ا ییاده سازی الگوریتم LMT در نرم افزار و کا با داده نرمال سازی شده به روش دسیمال

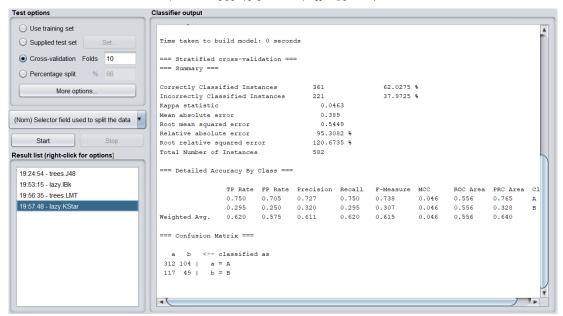


ا کا پیاده سازی الگوریتم LMT در نرم افزار و کا با داده نرمال سازی شده به روش انحراف معیار

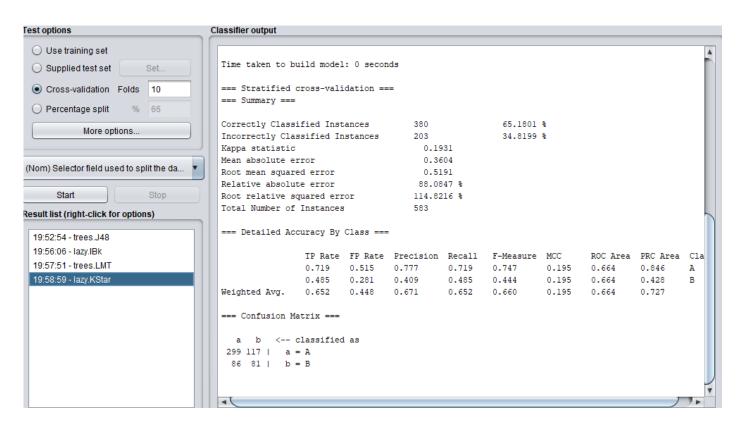
KStar				
دقت	نوع داده			
80.A88T	داده خام			
۶۲.۰۲۷۵	داده نرمال سازی شده با روش مین–ماکس			
80.11.1	داده نرمال سازی شده با روش دسیمال			
80.11.1	داده نرمال سازی شده با روش انحراف معیار			



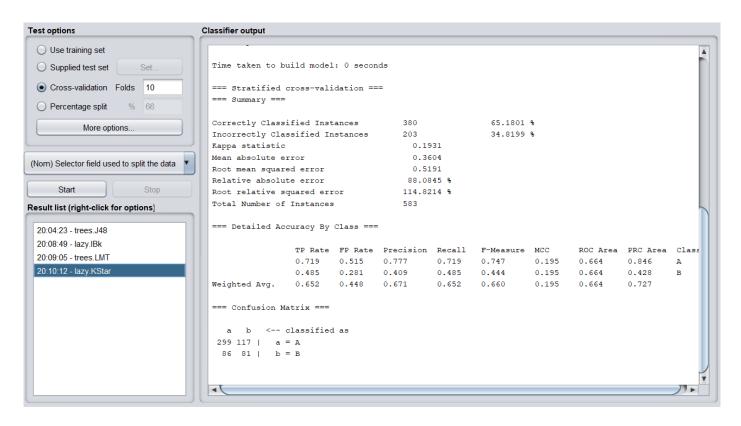
الم الكوريتم KStar در نرم افزار وكا با داده خام KStar بياده سازى الگوريتم



ا 🕻 پیاده سازی الگوریتم KStar در نرم افزار و کا با داده نرمال سازی شده به روش مین-ماکس

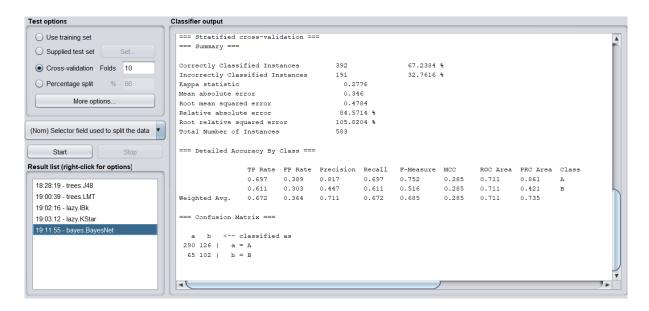


ا پیاده سازی الگوریتم KStar در نرم افزار وکا با داده نرمال سازی شده به روش دسیمال KStar پیاده سازی الگوریتم

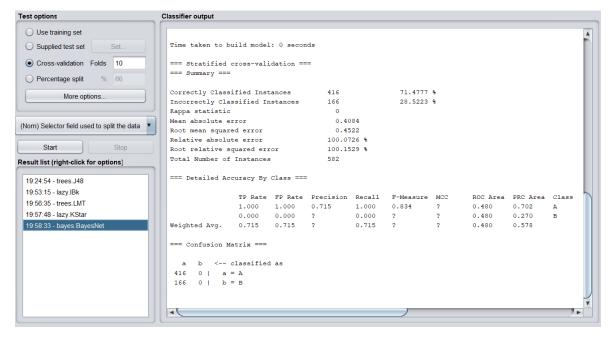


م ا پیاده سازی الگوریتم KStar در نرم افزار و کا با داده نرمال سازی شده به روش انحراف معیار

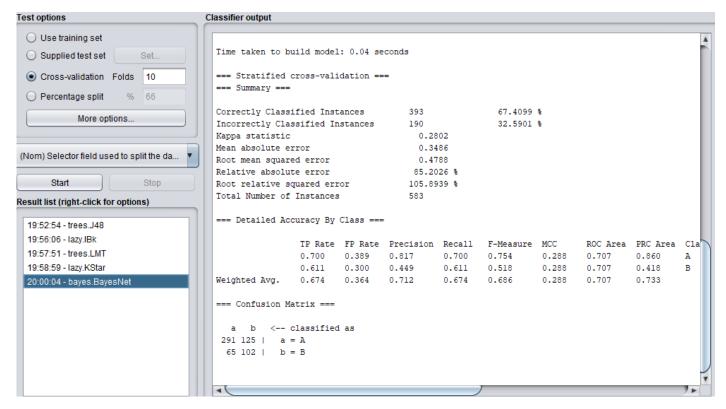
Bayes Net				
دقت	نوع داده			
۶۷.۲۳۸۴	داده خام			
٧١.۴٧٧	داده نرمال سازی شده با روش مین–ماکس			
<i>५</i> ४.५.११	داده نرمال سازی شده با روش دسیمال			
<i>५</i> ४.५.११	داده نرمال سازی شده با روش انحراف معیار			



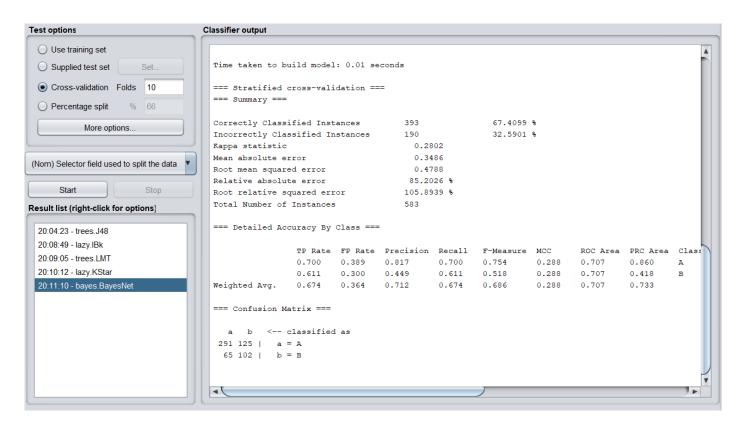
در نرم افزار وکا با داده خام Baysen Net پیاده سازی الگوریتم γ



۱۸ پیاده سازی الگوریتم Baysen Net در نرم افزار وکا با داده نرمال سازی شده به روش مین-ماکس

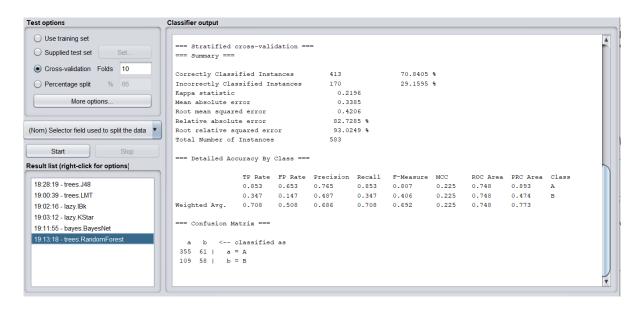


۱۹ پیاده سازی الگوریتم Baysen Net در نرم افزار و کا با داده نرمال سازی شده به روش دسیمال

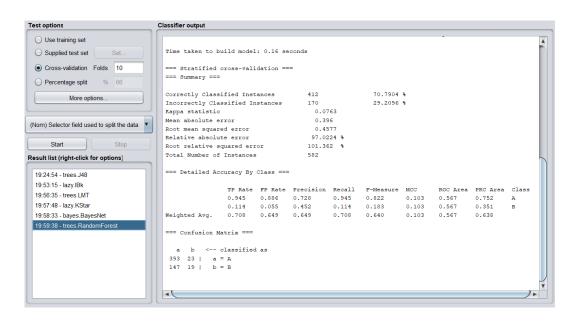


۲۰ پیاده سازی الگوریتم Baysen Net در نرم افزار وکا با داده نرمال سازی شده به روش انحراف معیار

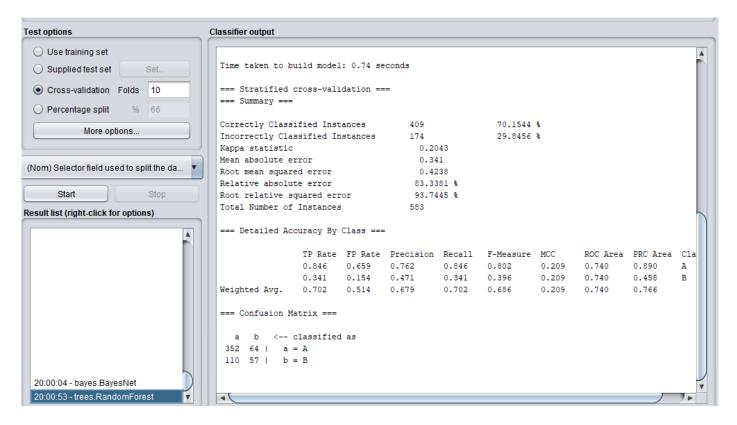
RandomForest				
دقت	نوع داده			
۷۰.۸۴۰۵	داده خام			
٧٠.٧٩٠۴	داده نرمال سازی شده با روش مین–ماکس			
٧٠.١۵۴۴	داده نرمال سازی شده با روش دسیمال			
<i>६</i> ९. <i>६</i> ٣९ <i>٨</i>	داده نرمال سازی شده با روش انحراف معیار			



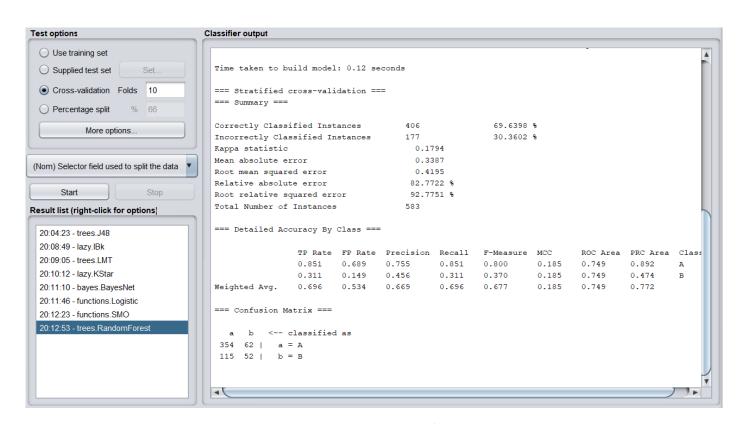
۲۱ يياده سازي الگوريتم RandomForest در نرم افزار و کا با داده خام



۲۲ پیاده سازی الگوریتم RandomForest در نرم افزار وکا با داده نرمال سازی شده به روش مین-ماکس

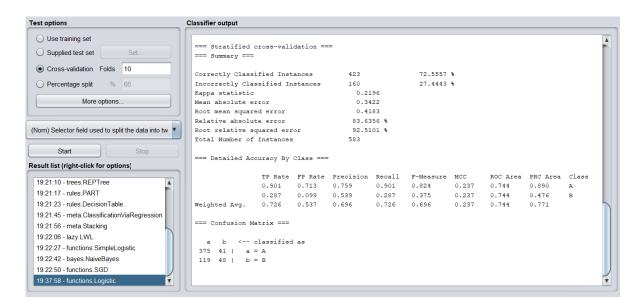


مرد الكوريتم RandomForest در نرم افزار وكا با داده نرمال سازی شده به روش دسیمال

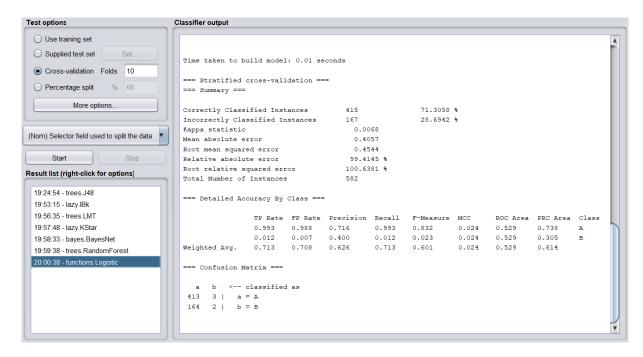


۲۴ پیاده سازی الگوریتم RandomForest در نرم افزار وکا با داده نرمال سازی شده به روش انحراف معیار

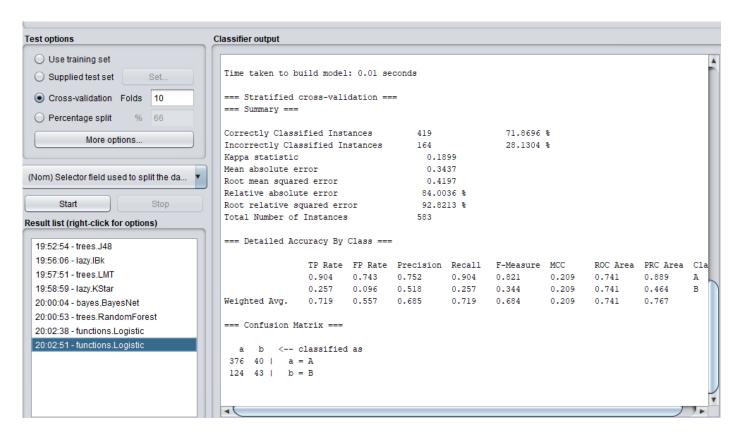
Logestic				
دقت	نوع داده			
٧٢.۵۵۵٧	داده خام			
۷۱.۳۰۵۸	داده نرمال سازی شده با روش مین–ماکس			
٧١.٨۶٩۶	داده نرمال سازی شده با روش دسیمال			
٧١.٨۶٩۶	داده نرمال سازی شده با روش انحراف معیار			



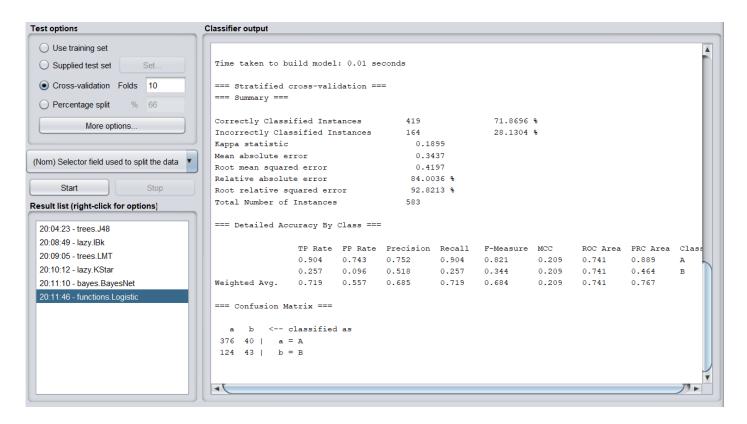
کا پیاده سازی الگوریتم Logistic در نرم افزار وکا با داده خام



۲۶ پیاده سازی الگوریتم Logistic در نرم افزار و کا با داده نرمال سازی شده به روش مین-ماکس

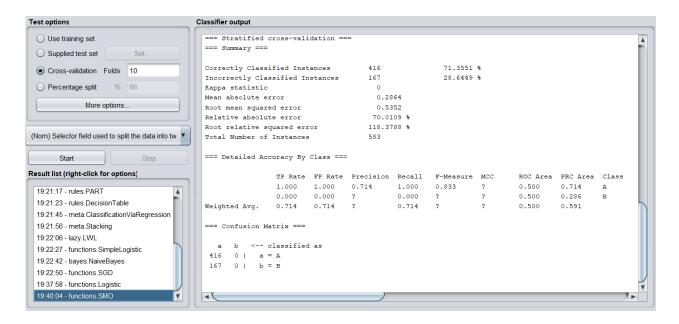


۲۷ پیاده سازی الگوریتم Logistic در نرم افزار و کا با داده نرمال سازی شده به روش دسیمال

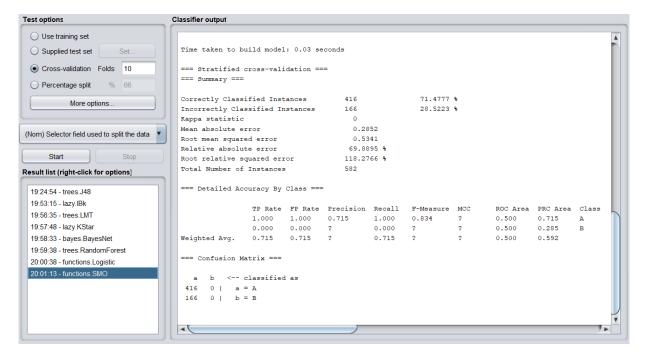


🔏 پیاده سازی الگوریتم Logistic در نرم افزار و کا با داده نرمال سازی شده به روش انحراف معیار

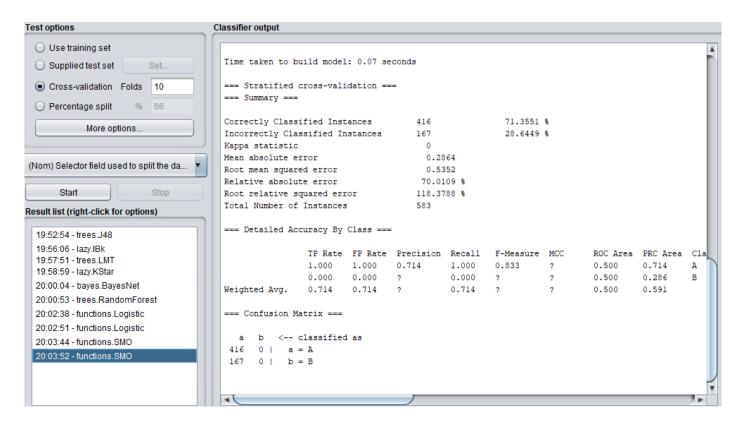
SMO				
دقت	نوع داده			
۷۱.۳۵۵۱	داده خام			
٧١.۴٧٧	داده نرمال سازی شده با روش مین–ماکس			
۷۱.۳۵۵۱	داده نرمال سازی شده با روش دسیمال			
۷۱.۳۵۵۱	داده نرمال سازی شده با روش انحراف معیار			

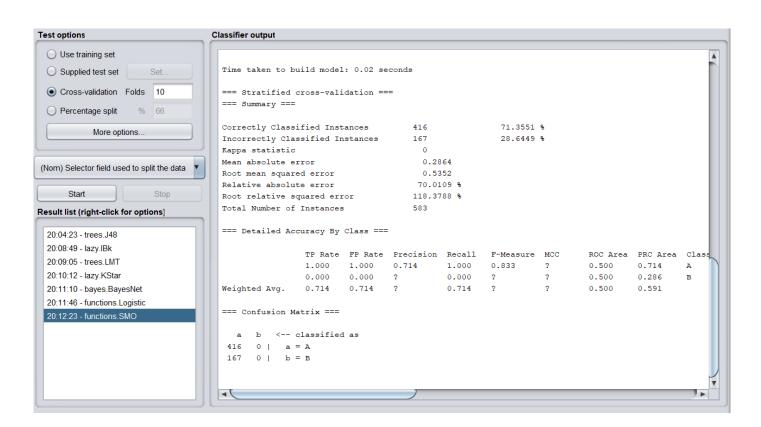


۲۹ پیاده سازی الگوریتم SMO در نرم افزار وکا با داده خام



۳۰ پیاده سازی الگوریتم SMO در نرم افزار وکا با داده نرمال سازی شده به روش مین-ماکس





حال با استفاده از تکنیک انتخاب ویژگی دو سناریو زیر را بررسی کردیم.

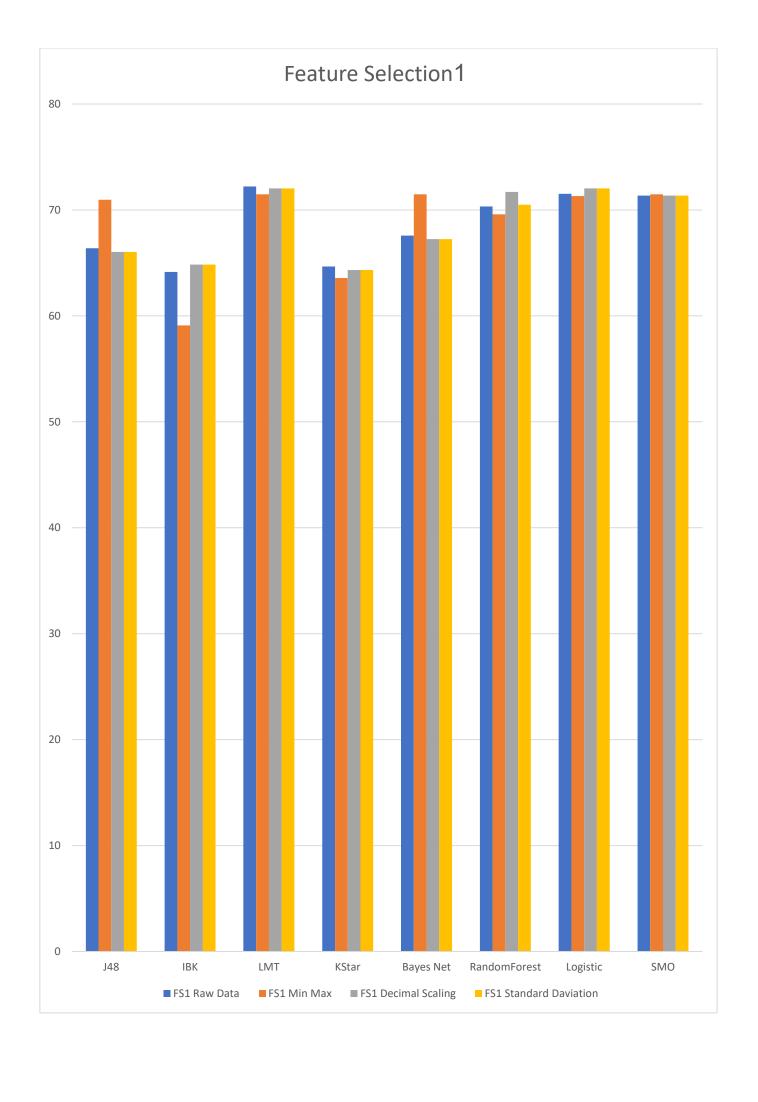
سناريو اول:

حذف ویژگی جنسیت و بررسی دقت الگوریتم های مختلف با داده خام و نرمال سازی شده.

به جهت بازدهی بیشتر جدولی از همه الگوریتم ها و داده ها تهیه شده، همچنین تصاویر نرم افزار و کا مربوط به همه تست های انجام شده با نام های قابل تشخیص و پیشوند FS در ضمیمه آورده شده است.

Algorithm	FS\ Raw Data	FS\ Min Max	FS\ Decimal Scaling	FS\ Standard deviation	
J£A	<i>۶۶</i> .۳۷۷	٧٠.٩۶٢٢	<i>\$\$.</i> •٣٧٧	<i>۶</i> ۶.۰۳۷۷	
IBK	<i>୨</i> ۴.۱۵٠٩	۵۹.۱۰۶۵	۶۴.۸۳۷	۶۴. ۸ ۳۷	
LMT	77.7177	Y1. ۴ YYY	VT.+ 417	Y7.+*17	
KStar	94.99۵۵	<i>۶</i> ٣.ΔΥ٣٩	54.TYY	۶۴.۳۲۲۵	
Bayes Net	۶۷.۵۸۱۵	Y1. ۴ YYY	FY.77%	۶۷.۲۳۸۴	
RandomForest	P&Y".•V	<i>9</i> 9.ΔΛΥ <i>9</i>	٧١.۶٩٨١	۲۰.۴۹۷۴	
Logistic	۷۱.۵۲۶۶	۷۱.۳۰۵۸	VY.• ۴17	Y7.+*17	
SMO	٧١.٣۵۵١	V1. ۴ VVV	٧١.٣۵۵١	۷۱.۳۵۵۱	

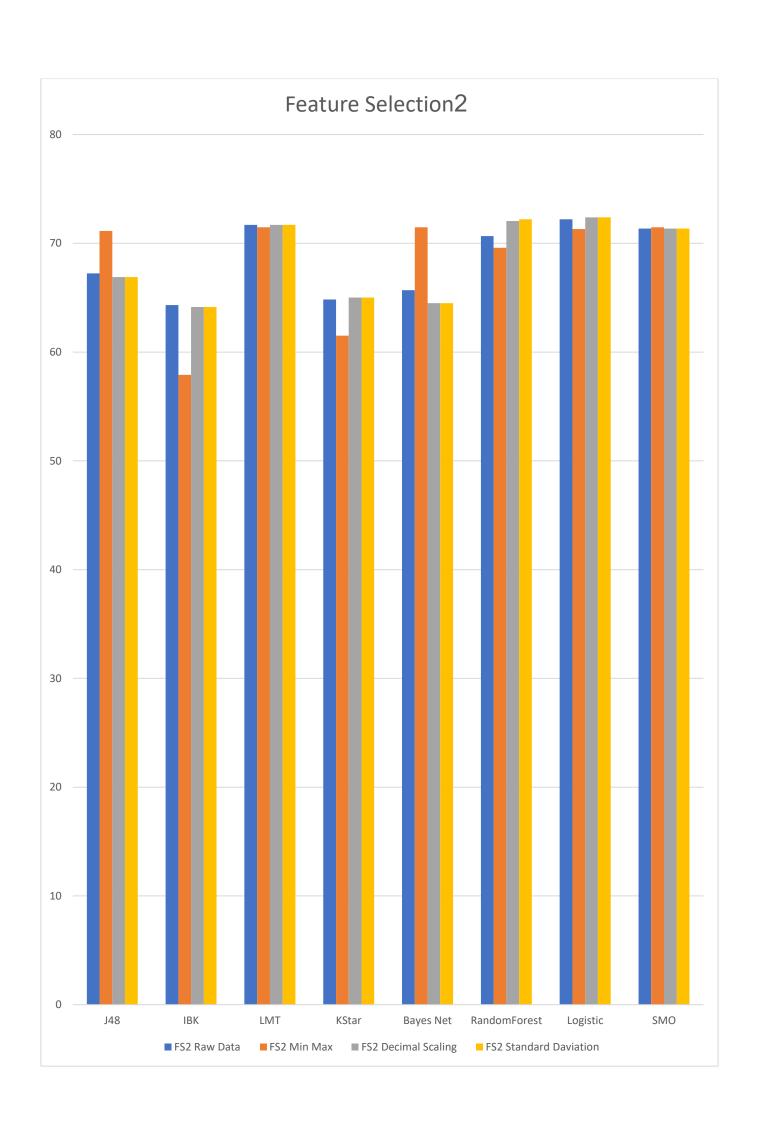
همانطور که مشاهده میشود، پیاده سازی الگوریتم LMT با استفاده از داده خام، بهترین دقت را گزارش میدهد.



- ۱. Age Age of the patient
- ۲. Gender Gender of the patient
- ۳. TB: Total Bilirubin
- F. DB :Direct Bilirubin
- **a. Alkphos Alkaline Phosphotase**
- 9. Sgpt Alamine Aminotransferase
- V. Sgot Aspartate Aminotransferase
- л. TP:Total Protiens
- A. ALB :Albumin
- No. A/G: Ratio Albumin and Globulin Ratio
- vi. Selector field used to split the data into two sets (labeled by the experts)

Algorithm	FS [†] Raw Data	FS ^۲ Min Max	FS [†] Decimal Scaling	FS ⁷ Standard deviation	
Jέλ	\$Y.YT%\$	V1.184	<i>۶۶.</i> ۸۹۵۴	<i>የ</i> ۶.۸۹۵۴	
IBK	۶ ۴ .۳۲۲۵	۵۷.۹۰۳۸	84.10.9	84.10.9	
LMT	V1.89A1	Y1. f YYY	٧١.۶٩٨١	Y1.59.k1	
KStar	۶۴.۸۳۷	81.017	۶۵.۰۰۸۶	۶۵.۰۰۸۶	
Bayes Net	9۵.99 ۴ ۷	Y1. f YYY	<i>\$</i> ۴ . ۴ 9 ۴	<i>\$</i> ۴. ۴ 9 ۴	
RandomForest	V+.999	99. <u>۵</u> ۸٧ <i>9</i>	VT.• ۴17	YY.717V	
Logistic	77.717	۷۱.۳۰۵۸	٧٢.٣٨۴٢	YY. T X F T	
SMO	٧١.٣۵۵١	Y1. * YYY	٧١.٣۵۵١	٧١.٣۵۵١	

همانطور که مشاهده میشود، پیاده سازی الگوریتم Logistic با استفاده از داده نرمال سازی شده به روش دسیمال و انحراف معیار، بهترین دقت را گزارش میدهد.



نتيجه گيري

Algorithm	Jέλ	IBK	LMT	KStar	Bayes Net	Random Forest	Logistic	SMO
Raw Data	۶۸.۹۵۳۷	94.10.9	٧٢.٣٨۴٢	80.A88Y	۶۷.۲۳۸۴	۵۰۶۸.۰۷	۷۲.۵۵۵۷	۷۱.۳۵۵۱
Min-Max	59.744	۵۷.۲۱۶۵	Y1. ۴ YYY	۶۲.۰۲۷۵	Y1. * YYY	٧٠.٧٩٠۴	۸۵۰۳.۱۷	Y1. ۴ YYY
Decimal Scaling	۶۸.۴۳۹۱	۶۳.۹۷۹۴	٧٢.٠۴١٢	80.11.	۶۷.۴·۹۹	٧٠.١۵۴۴	Y1. <i>\</i> \\$9\$	۲۱.۳۵۵۱
Standard deviation	۶۸.۶۱۰۶	۶۳.۹۷۹۴	٧٢.٠۴١٢	80.11.	۶۷.۴·۹۹	99.9 ٣ 9.	Y1. <i>\</i> \\$9\$	۲۱.۳۵۵۱
FS\ Raw Data	55.· TVV	84.10.9	77.7177	94.9900	۶۷.۵۸۱۵	70.7709	V1.0788	۲۱.۳۵۵۱
FS\ Min Max	٧٠.٩۶٢٢	۵۹.۱۰۶۵	V1.4VVV	۶۳.۵۷۳۹	V1. ۴ VVV	۶۹.۵۸۷۶	۸۵۰۳.۱۷	Y1. ۴ YYY
FS\ Decimal Scaling	55.·TVV	۶۴.۸ ۳ ۷	٧٢.٠۴١٢	۶۴.۳۲۲۵	۶۷.۲۳۸۴	٧١.۶٩٨١	٧٢.٠۴١٢	۲۱.۳۵۵۱
FS\ Standard deviation	55.· TVV	۶۴.۸۳۷	٧٢.٠۴١٢	۶۴.۳۲۲۵	۶۷.۲۳۸۴	74.44	٧٢.٠۴١٢	۲۱.۳۵۵۱
FS [†] Raw Data	۶۷.۲۳۸۴	۶۴.۳۲۲۵	٧١.۶٩٨١	۶۴.۸۳۷	90.99 ۴ V	V+.559	77.7177	۲۱.۳۵۵۱
FS [†] Min Max	٧١.١٣۴	۵۷.۹۰۳۸	V1.*VVV	۶۱.۵۱۲	V1.۴VVV	۶۹.۵۸۷۶	۷۱.۳۰۵۸	Y1. * YYY
FS7 Decimal Scaling	98.1924	84.10.9	٧١.۶٩٨١	۶۵.۰۰۸۶	54.44	٧٢.٠۴١٢	٧٢.٣٨۴٢	۷۱.۳۵۵۱
FS ⁷ Standard deviation	98.1924	84.10.9	٧١.۶٩٨١	۶۵.۰۰۸۶	54.44	77.717	٧٢.٣٨۴٢	۷۱.۳۵۵۱

